



به نام خدا

گزارش تمرین ششم درس الگوریتم‌های یادگیری ماشین

استاد راهنما: دکتر کمندی

سیده محیا معتمدی

۸۱۰۸۹۷۰۵۳

مینو احمدی

۸۱۰۸۹۷۰۳۲

دانشکده علوم مهندسی

پردیس دانشکده‌های فنی دانشگاه تهران

در این پروژه قصد داریم به کمک لایه های کانولوشنی و دیتاست fashion_mnist مدل classification را پیاده سازی کنیم.

بخش (a)

```
(x_train, y_train), (x_test, y_test) = tf.keras.datasets.fashion_mnist.load_data()

x_train = x_train / 255.0
x_test = x_test / 255.0

classes = ['T-shirt/top', 'Trouser', 'Pullover', 'Dress', 'Coat',
           'Sandal', 'Shirt', 'Sneaker', 'Bag', 'Ankle boot']
```

Figure ۱- لود کردن داده ها

load_data function

[\[source\]](#)

```
tf.keras.datasets.fashion_mnist.load_data()
```

Loads the Fashion-MNIST dataset.

This is a dataset of 60,000 28x28 grayscale images of 10 fashion categories, along with a test set of 10,000 images. This dataset can be used as a drop-in replacement for MNIST.

The classes are:

Label	Description
0	T-shirt/top
1	Trouser
2	Pullover
3	Dress
4	Coat
5	Sandal
6	Shirt
7	Sneaker
8	Bag
9	Ankle boot

Returns

- Tuple of NumPy arrays: (x_train, y_train), (x_test, y_test).

Figure ۲- توضیحات مربوط به دیتاست در سایت keras

با استفاده از دستور load data داده ها را از دیتاست گرفتیم و برای نرمال کردن داده ها همه داده ها را تقسیم بر ۲۵۵ کرده ایم

(زیرا رنج تمام داده ها از ۰ تا ۲۵۵ است)

این دیتاست شامل ۷۰ هزار دیتا ۲۸*۲۸ است که ۶۰ هزار تای آن برای آموزش و ۱۰ هزار تای آن برای تست است که در ده کلاس طبقه بندی شده اند.

در زیر ابعاد تصاویر آموزش و تست را میبینید .

```
print("Train Image shape: " ,x_train.shape)
print("Test Image shape: " ,x_test.shape)]
```

```
Train Image shape: (60000, 28, 28)
Test Image shape: (10000, 28, 28)
```

Figure ۳- ابعاد تصاویر داده‌ها آموزش و تست

ده تصویر از داده‌های آموزش را به عنوان مثال در زیر آورده‌ایم :

```
plt.figure(figsize=(15,15))
for i in range(10):
    plt.subplot(5,5,i+1)
    plt.xticks([])
    plt.yticks([])
    plt.imshow(x_train[i], cmap=plt.cm.binary)
    plt.xlabel(classes[y_train[i]])
plt.show()
```




Figure ۴- تصاویر کلاس‌های مختلف

بخش (b)

```

model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Conv2D( filters=32, kernel_size=(3, 3), strides=(1, 1), padding='valid', activation='relu', input_shape=(28, 28, 1)))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=(2, 2)))
model.add(tf.keras.layers.Dropout(rate=0.2))
model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(units=128,activation='relu'))
model.add( tf.keras.layers.Dense(units=10, activation='softmax'))

model.compile(loss=tf.keras.losses.sparse_categorical_crossentropy, optimizer=tf.keras.optimizers.Adam(), metrics=['accuracy'])
model.summary()

```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d_1 (Conv2D)	(None, 26, 26, 32)	320
max_pooling2d_1 (MaxPooling2D)	(None, 13, 13, 32)	0
dropout_1 (Dropout)	(None, 13, 13, 32)	0
flatten_1 (Flatten)	(None, 5408)	0
dense_2 (Dense)	(None, 128)	692352
dense_3 (Dense)	(None, 10)	1290
Total params: 693,962		
Trainable params: 693,962		
Non-trainable params: 0		

Figure ۵- معماری مدل

مدل را با استفاده از دستور Sequential طراحی کرده ایم در ابتدا یک لایه کانولوشن ۲ بعدی با کرنل سایز ۳*۳ و ابعاد input ۲۸*۲۸ و تابع فعالساز relu و تعداد ۳۲ تا فیلتر اضافه کردیم .

در لایه های بعدی از لایه های maxpooling استفاده کرده ایم که یکی از لایه های اصلی در طراحی شبکه کانولوشن است در این لایه بیشترین مقدار داده ای که در لایه قبلی توسط کرنل به ازای هر فیلتر به دست آمده است، انتخاب میشود.

در مرحله بعدی یک لایه dropout با مقدار ۰.۲ اضافه کرده ایم تا از overfitting جلوگیری شود و شبکه بتواند تعمیم بهتری برای داده تست داشته باشد .

در انتها دو لایه dense (fully connected) اضافه کرده ایم که ابعاد خروجی آن ها به ترتیب ۱۲۸ و ۱۰ است در لایه آخر fully connected از اکتیویشن فانکشن soft-max استفاده کرده ایم و تعداد نوروں ها لایه آخر برابر ده است چون ده کلاس برای داده ها وجود دارد.

هم چنین از تابع خطا sparse_categorical_crossentropy و بهینه ساز adam استفاده کرده ایم.

کد های مربوط به این بخش و شمای کلی از مدل را میتوانید در بالا مشاهده کنید.

در نهایت مدل را با validation_split=۰.۱, epochs=۲۰, batch_size=۲۵۶ و callback در حالت early stopping آموزش داده ایم .

```

from gc import callbacks
x_train = np.expand_dims(x_train, -1)
x_test = np.expand_dims(x_test, -1)
callback = tf.keras.callbacks.EarlyStopping(
    monitor="val_loss",
    min_delta=0,
    patience=3,
    verbose=0,
    mode="auto",
    baseline=None,
    restore_best_weights=False,
)
history = model.fit(x_train, y_train, batch_size=256, epochs=20, validation_split=0.1, verbose=1, callbacks = [callback])

```

Figure ۶- callback و تابع fit

نتایج epoch های آخر به شرح زیر است :

```

Epoch 12/20
211/211 [=====] - 26s 123ms/step - loss: 0.1691 - accuracy: 0.9383 - val_loss: 0.2378 - val_accuracy: 0.9137
Epoch 13/20
211/211 [=====] - 26s 123ms/step - loss: 0.1597 - accuracy: 0.9416 - val_loss: 0.2396 - val_accuracy: 0.9168
Epoch 14/20
211/211 [=====] - 27s 128ms/step - loss: 0.1530 - accuracy: 0.9440 - val_loss: 0.2374 - val_accuracy: 0.9160

```

Figure ۷- نتایج ایپاک های آخر

در نمودار های زیر میتوان نمودار پیشرفت دقت و خطا را مشاهده کنید.

accuracy and loss of model




Figure A- نتایج خطا و دقت

با استفاده است دستور `model.predict` داده های تست را به مدل اعمال کردیم و خروجی را بدست آوردیم برای اینکه کلاس انتخاب شده توسط مدل را پیدا کنیم از دستور `np.argmax` کلاس با بیشترین احتمال را میگیریم و در نهایت با استفاده از

دستور `classification report` محاسبه کرده‌ایم که در هر کلاس، در چند درصد از مواقع مدل عملکرد خوبی از خود نشان می‌دهد .

داده های مربوط به این بخش در زیر آمده است.

```
predicted = model.predict(x_test)
predicted = list(np.argmax(predicted, axis=1))
print(classification_report(y_test, predicted, target_names=classes))
```

	precision	recall	f1-score	support
T-shirt/top	0.87	0.87	0.87	1000
Trouser	0.99	0.98	0.99	1000
Pullover	0.88	0.87	0.88	1000
Dress	0.89	0.96	0.92	1000
Coat	0.89	0.85	0.87	1000
Sandal	0.98	0.98	0.98	1000
Shirt	0.76	0.76	0.76	1000
Sneaker	0.95	0.98	0.96	1000
Bag	0.98	0.98	0.98	1000
Ankle boot	0.98	0.96	0.97	1000
accuracy			0.92	10000
macro avg	0.92	0.92	0.92	10000
weighted avg	0.92	0.92	0.92	10000

Figure ۹ - نتایج به دست آمده از داده‌های تست به تفکیک کلاس

بخش C

همان طور که در بخش قبل ذکر شده در طراحی این مدل از `dropout=0.2` (تا از `overfitting` جلوگیری شود و شبکه بتواند تعمیم بهتری با داده تست داشته باشد)

```
model.add(tf.keras.layers.Dropout(rate=0.2))
```

Figure ۱۰ - Dropout

و `call back` حالت `early stopping` استفاده شده است که در این بخش داده `validation loss` را مانیتور میکنیم و مقدار `patience` را هم برابر ۳ قرار میدهیم در نتیجه هر زمان که مقدار `validation loss` در سه `epoch` پشت سر هم کاهش پیدا نکند مدل آموزش را متوقف میکند میتوانیم در قسمت قبل مشاهده کنیم که با اینکه بیست `epoch` برای آموزش در نظر گرفته بودیم به دلیل قرار دادن `callback` مدل تنها چهارده `epoch` را طی کرده است .

```
callback = tf.keras.callbacks.EarlyStopping(  
    monitor="val_loss",  
    min_delta=0,  
    patience=3,  
    verbose=0,  
    mode="auto",  
    baseline=None,  
    restore_best_weights=False,  
)
```

callback - 1) Figure